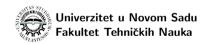
NoSQL baze podataka

Predavanje 10: Baze vremenskih serija, Baze podataka sa višestrukim modelima, Distribuirani FS, Big Data



Uvod

- Baze podataka vremenskih serija predstavljaju najmladju grupu NoSQL baza podataka
- ► Kao potpun model, pojavile su se relativno skoro
- Medjutim, našle su dosta primena u različitim tipovima aplikacija

- Ovaj model podataka reprezentuje često jednu velidinu i prikazuje njeno kretanje kroz vreme
- Prikazuje kako se neka veličina kretala kroz vreme
- Pored osnovne ideje, ove baze podataka često dopuštaju i dodavanje dodatnih elemenata koje omogućavaju lakšu pretragu i upite
- Obično imaju prilično ekspresivan upitni jezik

- Za razliku od većine drugih baza podataka, ove baze, obično ne perzistiraju podatke jako dugo
- Obično definišemo nekakav period retencije koliko podaci treba da budu perzistentni
- Nakon tog vremena, podaci bivaju obrisani
- Naravno, ovo je moguće isključiti

- Ali zbog svoje specifičnosti obiņo ne čuvamo podatke jako dugo
- Medjutim, možemo sačuvati neke bitne karateristike naših podataka

- Vremenske servije kao pojam, se dosta koriste u ekonomiji pa čak i nauci o podacima
- Kao proces predickije su izuzetno koristan model, zato što mogu da otrkiju sezonske trendove
- korisnici shodno tim trendovima mogu da reaguju

Sam model podatka je prilično pozanat i dosta se koristi i u statistici i statističkim analizama

- ▶ Baš iz razoga dugogo postojanja, i odavno se koriste i u samom računarstvu
- ▶ Nekada su se relacione baze koristile a ovakve mehanizme
- Kada je količina podataka porasla, one više nisu mogle da odgovore na ove zahteve
- Naredni model koji se dosta koristi za modelovanje ovih podataka je svakako kolonski orijentisane baze
- ▶ Apache Cassandra je čest primer baze koju ljudi koriste za ove podatke

- ▶ lako Apache Cassandra može u velikoj meri da odgovori ovih zahtevima, stvorili su se uslovi za potpuno nov model
- Početkom 2012 godine, moguće i pre, počine implementacija ovog modela podataka iz proste potrebe i realnim problemima
- ▶ 2012 godine kompanija SoundCloud implementria svoj prozivod Prometheus, zasnovan na Google-ovom sitemu Borgman
- Gde je potrebno da se podaci skaldište na specifičan način, i da se podacima pristupa na specifičan način

- Ovo je otvorilo vrata za potpuno nov mode nosql baze podataka i za razne nove upotrebe
- Pojavom ideje o Internet of Things apliakcijama, ove baze podataka su dobile itekako na značaju
- Prmetheus kao unutrašnje skladište koristi LebelDB engine, kao i većina modernih sistema i napisan je u GO-u
- Prilično važan i bitan proizvod pre svega u Cloud i okruženju mikroservisa
- Kao i sivm drugim okruženjima gde je model podataka zasnovan na nekakvih metrikama kroz vreme

- Drugi važan projekat za ove baze je svakako i InfluxDB
- ► Sa Inicijalna objana modela je bila 2013

- ➤ Za razliku od Prometheus-a, ovaj sistem ne koristi LevelDB već svoj novi mehanizam za skladištenje vrlo sližn LevelDB-u
- Optimizovan za malo drugačije upite, takodje napisan u GO-u
- Omogućava brzo pisanje i čitanje podataka

- ▶ Obe baze su izuzetno bitne za novi rast i razvoj Cloud i raznih drugih sistema
- Omogućile su rad sa metrikama na znatno jednostavniji prirodniji način
- I na taj način stvorile potupno nove pravce razvoja, rada i istraživanja
- Metrike su izuetno bitne za svaki aspekt pre svega modernih i komplikovanih kako apliakcija tako i samih sistema
- Model koji nikada ne treba izgubiti iz vida!

Uvod

- ▶ Svi modeli podatka o kojima smo pričali su obiçno bili nezavisni jedan od drugog
- Obiņo je jedan sistem za skladištenje podržavao jedan model
- Ovde je izuzetak TitanDB koji je koristio Apache Cassandru za skladištenje grafova
- Medjutim, javila se suprotna ideja ovom pravcu
- Razviti bazu podataka koja je sposobna da skladišti razne modele podataka

Ideja je vrlo jednostavna

- Napraviti takav sistem da bude sposoban da čuva podatke u raznim modelima
- Obezbediti da za to se ne koriste razni sistemi, već samo jedan
- Prednsoti ovog pristupa su svakako jednostavnost
- Ne moramo da instaliramo i podesimo nekoliko sistema za skladištnje podatkam već samo jedan

- Ako pogledamo većina NoSQL baza podataka koriste vrlo sličan model za skaldištenje podataka
- Većnu podataka obično možemo posmatrati kao ključ-vrednsot
- Na kraju podaci i završe na disku na taj način ili nešto vrlo slično tome
- Izuzetak su svakako graf baze

- Ako iskoristimo ovo znanje, možemo vrlo jednsotavno napraviti sistem koji je sposoban da radi sa raznim modelima podatka
- Naravno, ne možemo postići iste osobine uvek kao i potpuno nezavisni sistemi
- ► Ali možmeo se jako dobro približiti

 Naravno uvek moramo biti sveni da neka ograničenja postoje i ne možemo ih eliminisati Dobar primer je svakako OrinetDB

- Ovaj sistem je sposoban da skladišti podatke i i NoSQL i SQL
- Objavljena 2010 godine i napisna u Javi
- Omogućava rad sa graph, document, key/value, and object modelima
- Jasno ograničemje koje ovde imamo je svakako odnos SQL i noSQL baza

- ▶ Da bi postigli ovu varijantu *One ring to rule them all* Orint je moram da pribegne nekim zanimljivim odlukama
- ▶ Pre svega, relacijama u relaciom modelu se upravlja kao u bazama podataka grafova sa direktnim vezama izmedju zapisa
- Na taj način imamo ograničemjne, ali jedan sistem je sposoban da skladišti razne oblike podataka

- ► Pored OrinetDB-a, imamo i razne druge primere baza koje mogu da ponude iste ili slične osobine
- Neke od njih idu čak i korak dalje

- Primer je svakako Aerospike sistem koji omogućava mudlit model
- Ovaj sistem je izuzetno brz obzirom da se izvršva u memoriji
- Kao takav ima odredjene prednsti, ali i mane u odnosu na sistmee koji skladite podatke na disku
- Ali je optimizovna i za razne real-time apliakcije

Uvod

- lako ovi sistemi ne spadaju direktno u baze podataka, možemo ih svakak posmatrati kao sisteme koji skladište izuetno velike količine podataka
- Pored toga omogućavaju da se podacima pristupi i da se podaci obrade
- ▶ Omogućavaju čak i nekakav jedinstevn jezik/model za upite MapReduce

Distribuirani FS

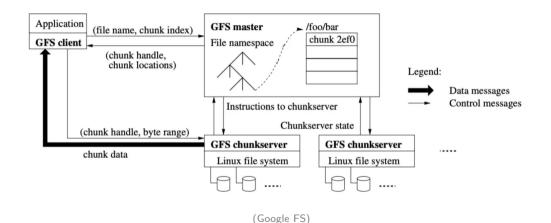
0000000

Postoje razne implementacije distribuiranih FS-a

- Na ovom kursu ćemo se fokusirati na one variajnte koje su proistekle iz radova Google FS-a
- Pre svega zato što omogućavaju bitan momenat u skladištenju i obradi velike količine podataka u Cloud-u
- I sa druge strane rešili su dosta problema koje su prethodnici imali
- I pored toga liče na sisteme za skladištenje podatka, a nekada se baš za to i koriste ili nekakvih derivati

Google FS, Hadoop FS

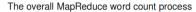
- ▶ Pošto je GFS razvijen za potrebe kompanije Google i zatvoren je za javnost ne možemo tačno zanti sve detalje
- Srećom objavili su rad, pa možemo steći nekakve informacije
- Nakon rada nastao je Hadoop FS i započela je nova era Big Data sistema

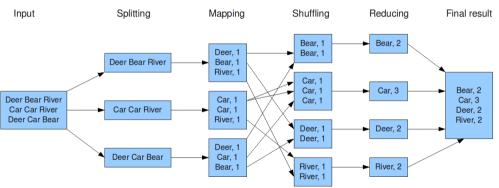


MapReduce

- Omogućava upravljanje velikum količinama podataka posredstvom distribuirane mreže čvorova.
- ▶ Deli velike zadatke na manje delove pogodne za paralelno procesiranje
- MapReduce okruženje Upravlja izvršenje MR algoritma i Obezbedjuje spregu s korisnikom

- Map korak
 - Glavni čvor
 - Preuzima ulazne podatke
 - Deli ulazne podatke na manje delove
 - Distribuira radne delove u manje čvorove
 - Radni čvor
 - Procesiraju dodeljene zadatke
 - Vraćaju odgovor glavnom čvoru
- Reduce korak
 - Glavni čvor
 - Preuzima rezultate radnih čvorova
 - Kombinuje rezultate sa ciljem dobijanja traženog rezultata

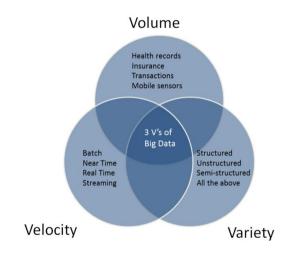




 $(\mathsf{MapReduce})$

Uvod

- NoSQL baze podatka nisu samo korisne za tipične korisničke aplikacije
- Ovi sistemi se zbog svoje osobine da skladište izuetno velike količine podatka i mogućnosti skaliranja koriste i u raznim drugim situacijama
- pojava GFS/HDFS-a i raznih nosql baza podatka dovela je do razvoja nove oblasti
 Big Data
- Skaldištiti, obrada i održavanje velike količine raznih oblika podataka (data engineering), i izvlačenje korisnik informacija iz tih podataka (razne analitičke pozicije)



(The application of Big Data in medicine: current implications and future directions)

- ▶ Nije uvek jasno šta je tačno Big Data niti koliko je zapravo Big
- Ali sa sogurnošću mov zemo reći da količina podatka koje obradi i skladišti npr. google, Facebook, twitter, itd. zasigurno jeste Big Data
- ▶ Tokom godina, razvijeni su razni alati koji koriste nosql baze kao osnovu ili GFS/HDFS, ali i sitemi koji koriste slične principe
- Neki od njih su znatnna unapredjenja od samih skladišta podataka i mogućavaju razne dodatne primene i mogućnosti
- Sve u svemu Big Data je jedna zanimljiva oblast i tu je da ostane, bar neko vreme
 :)

Dodatni materijali

- Making Sense of NoSQL A guide for managers and the rest of us
- Database Internals
- NoSQL Distilled A Brief Guide to the Emerging World of Polyglot Persistence
- Seven Databases in Seven Weeks
- Prometheus: A Next-Generation Monitoring System (Talk)

Pitanja

Baze podataka vremenskih serija

Pitanja :) ?