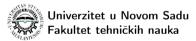
# Hadoop Distributed File System

NoSQL baze podataka



# Hadoop Distributed File System

- Zvanična dokumentacija
- ► Go driver



# Hadoop

Hadoop

- Open-source
- Framework za skladištenje i procesiranje velikih skupova podataka
- Od GB do više PB podataka
- Distribuiran sistem
- Horizontalno skaliranje na više hiljada računara
- ► MapReduce koncept
- High Availability Distributed Object Oriented Platform
- …ili ime igračke slončeta sina jednog od kreatora

# Osnovne informacije

- Distribuirano skladište podataka
- Paralelizacija obrade podataka
- ▶ Podaci se skladište na "običnom" hardveru gde se procesiraju u paraleli

## Komponente sistema

- ► HDFS Hadoop Distributed File System
- ► YARN Yet Another Resource Negotiator
- MapReduce paradigma obrade velikih skupova podataka
- Hadoop Common zajedničke komponente

#### **HDFS**

- Osnovna komponenta
- Distribuirani sistem za skladištenje (izuzetno velikih) datoteka
- Optimizovane metode za čitanje podataka
- Fajlovi se dele na i skladište u vidu blokova
- Predefinisana veličina bloka 128MB
- Radi na "običnom" hardveru
- Prati master-slave arhitekturu
  - NameNode iedan u sistemu
  - DataNode više u sistemu

## NameNode

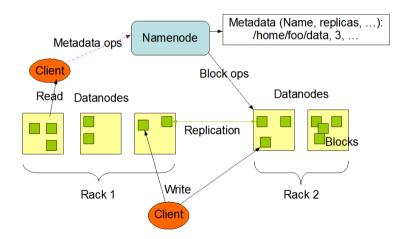
- Master server
- ► Rukovodi fajl sistemom
- Skladišti metapodatke o fajlovima
  - Putanja
  - Lokacija blokova
  - Status replikacije
  - **.**..
- Klijent komunicira sa NameNode da započne kreiranje fajla skladištenje metapodataka

## **DataNode**

- ► Slave server
- Skladišti blokove na fajl sistemu
- ► Rukuje replikacijom
- ► Klijent komunicira sa DataNode da skladišti sadržaj fajla

## HDFS arhitektura

#### **HDFS Architecture**

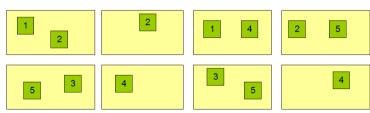


# HDFS replikacija

#### **Block Replication**

Namenode (Filename, numReplicas, block-ids, ...) /users/sameerp/data/part-0, r:2, {1,3}, ... /users/sameerp/data/part-1, r:3, {2,4,5}, ...

#### Datanodes



## **Primer**

U okviru primera RestHdfs upotrebljeni su:

- 1. Hdfs skladište podataka
- 2. Docker kontejnerizacija rešenja (i "instalacija" baza)
- 3. Go implementacija primera

#### Zadaci

- Proširiti servis tako da podržava:
  - prosleđivanje fajla u okviru HTTP zahteva
  - dobavljanje fajla u okviru HTTP odgovora
  - uključi bazu podataka koja će omogućiti skladištenje metapodataka (autor, opis, vreme kreiranja,...) za fajlove
- ▶ Bonus: Istražiti razliku između Mkdir i MkdirAll metoda
- ➤ Za radoznale: Istražiti MapReduce paradigmu, kao i njene upotrebe, i prezentovati istraživanje na sledećim vežbama